

Développement d'une application d'aide au diagnostic de tumeurs cérébrales basée sur les réseaux de neurones artificiels

Brad Niepceron, Filippo Grassia, Ahmed Nait-Sidi-Moh
Université de Picardie Jules Vernes

INTRODUCTION

Contexte

La **segmentation des IRM cérébrales** est une étape cruciale dans le développement d'applications pour les neurosciences et le domaine clinique.

Les artefacts inhérents aux IRM, la diversité de forme et la rareté de certains types de tumeurs rendent les tâches de diagnostic complexes due à des variations individuelles trop importantes.

L'utilisation de **réseaux de neurones artificiels (RNAs)** paraît, aujourd'hui, être une solution convaincante quant au développement de telles applications [1][2].

Problématique

Comment construire un système de détection automatique de tumeurs cérébrales en tenant compte de la variétés des tissus cancéreux?

Objectifs

Développer un système de segmentation d'IRM end-to-end basé sur des RNAs.

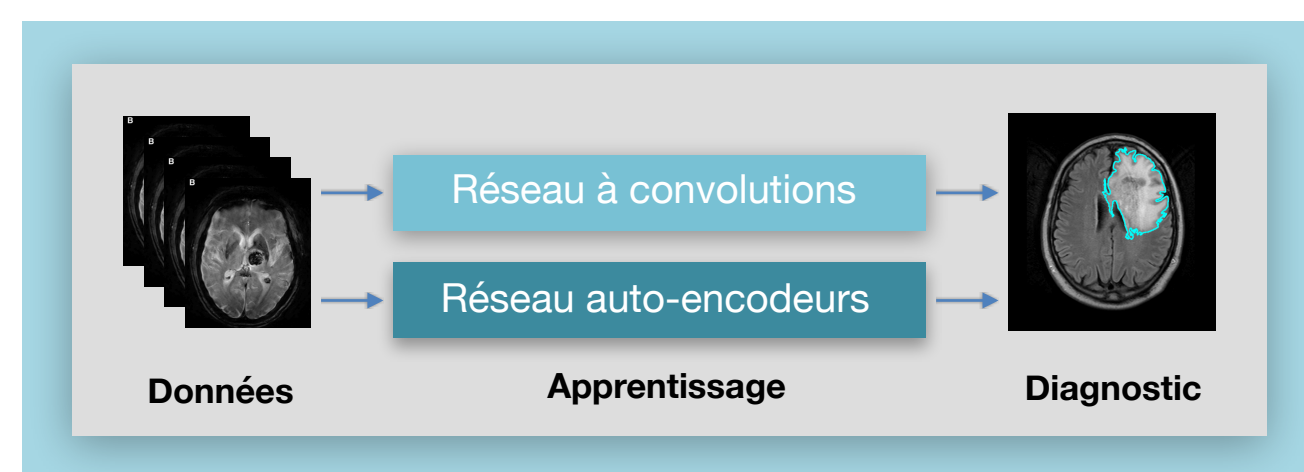


Figure 1 : Système de segmentation de tumeurs

CONTRIBUTIONS

1. Réseau de neurones à convolutions

Nous combinons l'architecture **TwoPath CNN** [3] aux blocs de convolutions de l'architecture **ResNet** [4]. Le modèle réalise la segmentation d'un cerveau en classifiant tous les pixels présents sur l'ensemble des 4 séquences d'une IRM cérébrales.

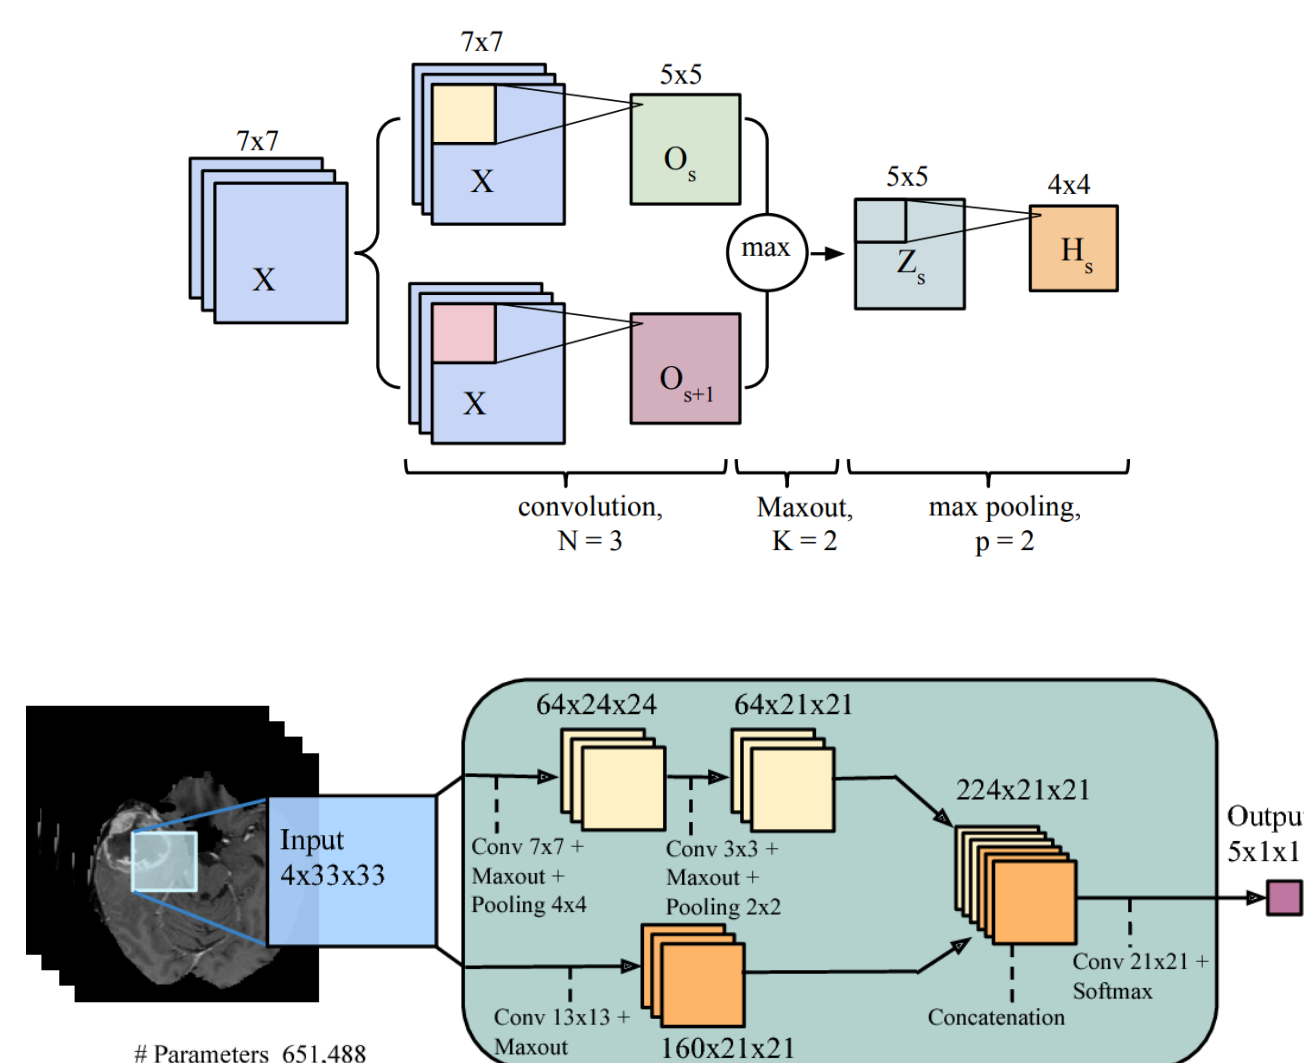


Figure 2 : TwoPath CNN [3]

L'architecture TwoPath CNN est augmentée dans le but d'améliorer ses performances.

Bloc de convolutions ResNet

Les convolutions sont remplacées par des blocs de convolutions ResNet.

But recherché :

- Éviter le problème de la disparition du gradient
- Réduire le nombre d'opérations
- Réduire le temps d'apprentissage

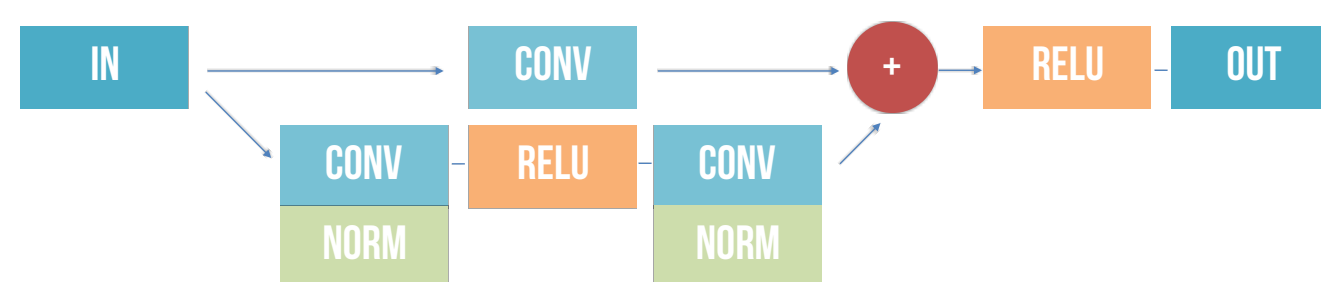


Figure 3 : Block de convolutions ResNet

Normalisation de groupe

Chaque sortie de couche de convolution est normalisée par une couche Group Normalization [5].

But recherché :

- Utiliser de petites tailles de batches
- Réduire le besoin en RAM
- Améliorer les performances du modèle
- Éviter le sur-apprentissage

$$\mu_i = \frac{1}{m} \sum_{k \in S_i} x_k, \quad \sigma_i = \sqrt{\frac{1}{m} \sum_{k \in S_i} (x_k - \mu_i)^2 + \epsilon},$$

Avec μ la moyenne, σ la variance et S un ensemble de pixels

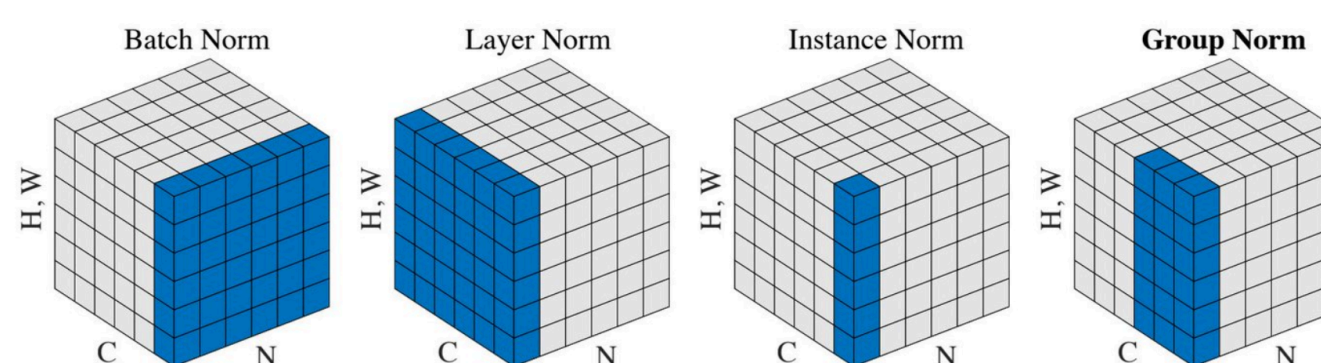


Figure 4 : Méthodes de normalisation

2. Auto-encodeur adverse à convolutions

Nous proposons un modèle d'auto-encoder adverse à convolutions pour la création d'une **méthode de segmentation semi-supervisée**.




Figure 5 : Auto-encodeur adverse

L'architecture suit **3 phases** d'entraînement :

- Encodeur/décodeur = **Reconstruction**
- Discriminateur = **Régularisation**
- Encodeur seul = **Classification / Segmentation**





Figure 6 : Modèle de segmentation semi-supervisée

RÉSULTATS OBTENUS

	Dice score (Tumor core)
Notre modèle	0.83
Havaei et al.	0.78
Tustison et al.	0.79
Zhao et al.	0.79

RÉSULTATS ATTENDUS

Nous pensons qu'en entraînant l'auto-encodeur adverse à reconnaître des tissus sains nous permettrait de traiter la problématique par la **détection d'anomalies**.



CONCLUSION

Synthèse

- Les modèles parviennent à segmenter des gliomes de haut et bas grade.
- Le bloc ResNet est particulièrement efficace pour la segmentation d'image.

Limites

- Plusieurs phases d'entraînement sont nécessaires pour pouvoir segmenter tout type de tumeurs.

Perspectives

- Rendre la tâche de segmentation **sémantique** pour obtenir un diagnostique complet par l'usage d'**ontologies**.

RÉFÉRENCES

- [1] S. Pereira et al. Deep convolutional neural networks for the segmentation of gliomas in multi-sequence mri. Proceedings MICCAI-BRATS, pages 52–55, 2015.
- [2] M. Ozkan et al. Neural-network-based segmentation of multi-modal medical images: a comparative and prospective study. IEEE transactions on Medical Imaging, 12(3):534–544, 1993.
- [3] M. Havaei et al. Brain tumor segmentation with deep neural networks. Medical image analysis, 35:18–31, 2017.
- [4] K. He et al. Deep residual learning for image recognition. arXiv preprint arXiv:1512.03385,2015.
- [5] Wu, Y., He, K.: Group normalization. In: European Conference on Computer Vision (ECCV) (2018).
- [6] Makhzani, et al. "Adversarial autoencoders." arXiv preprint arXiv:1511.05644 (2015).